

可解释的谣言检测

人工智能导论大作业 2026 | 小组成员：待填写姓名、学号、贡献比例

摘要。本项目实现英文推文谣言检测系统，输入文本后输出 0/1 标签和中文判断依据。默认主模型为三路 TF-IDF + Logistic Regression 集成，使用 train_clean.csv 训练，不依赖学校 API 或本地缓存，在 val.csv 上复现 Accuracy 0.8803。备选增强模型 FinalRumourDetectClass 使用可复现的分级话术信号，Accuracy 达到 0.8928。项目同时保留数据清理、事件级错误分析、阈值实验、5-fold 交叉验证、LLM 复核和失败实验记录。

关键词：谣言检测；可解释机器学习；TF-IDF；逻辑回归；RAG；大语言模型复核

1. 任务与合规性

课程要求模型对推文输出 0/1 标签，并给出一段判断依据。GitHub 需包含 README、report.pdf、代码和支持文件。本项目默认检测类为 RumourDetectClass，提供 classify(text)、explain(text) 和 predict(text)。默认复现路径只依赖仓库中的数据、模型和 Python 依赖；学校 API 的 deepseek-reasoner 仅作为可选解释增强与低置信复核实验。

2. 数据质量与预处理

原始训练集 2840 条，验证集 401 条。预处理包括 HTML 反转义、小写化、URLTOKEN、USERTOKEN 和 hashtag 展开。数据审计发现训练集中存在 3 组、7 行预处理后文本相同但标签冲突的异常样本；验证集无同类冲突。因此保留原始 train.csv，额外生成 train_clean.csv 训练。

3. 模型架构




图 1：默认主模型流程

阶段	输入/处理	输出
清洗	HTML 反转义、URL/用户/hashtag 归一化	稳定文本表示
特征	词级 1-2/1-3 gram + 字符级 2-6/3-6 gram	三路 TF-IDF 向量
分类	三组 Logistic Regression 概率平均	谣言概率与 0/1 标签
解释	TF-IDF 特征值与权重乘积	支持谣言/非谣言的局部证据
增强	低概率非谣言样本检查分级话术信号	备选高召回预测

默认模型训练三组互补管线，解释模块计算当前文本中每个 TF-IDF 特征值与模型权重的乘积。解释不引入外部事实，只反映模型在当前样本上的局部判定依据。

4. 实验与结果

方案	Accuracy	Macro-F1	Rumor F1	说明
RumourDetectClass	0.8803	0.8757	0.8519	默认主模型，TN/FP/FN/TP=215/11/37/138
低置信 FN 复核	0.8828	0.8784	0.8554	复核 79 条，覆盖 1 条，无新增 FP
LLM 高置信覆盖	0.8828	0.8787	0.8563	调用 70 条，覆盖 3 条，仅作增强实验
FinalRumourDetectClass	0.8928	0.8892	0.8693	默认不读 LLM 缓存，TN/FP/FN/TP=215/11/32/143

5-fold 交叉验证 Accuracy 为 0.8641 ± 0.0176 。train 内部 dev 阈值实验选择 0.51，但应用到 val.csv 后 Accuracy 降至 0.8753，因此最终保留 0.5。事件级分析发现 event 0 和 event 1 的错误主要是 false negative，说明模型偏保守。

5. 增强方案与失败实验




图 2: 备选增强模型的分级信号流程

FinalRumourDetectClass 只在本地模型判为非谣言且 $\text{prob_rumor} \leq 0.25$ 时检查分级话术信号。强信号直接覆盖为谣言，中等信号仅在 $\text{prob_rumor} + \text{bias} \geq 0.50$ 时覆盖。远程分支曾记录 0.9027 Accuracy，但依赖验证集后处理脚本与本地缓存，因此仅作为探索记录。稠密语义特征、event 特征、L1 正则化、直接 LLM 接管等尝试未稳定提升效果，已在 docs/ 中作为失败/风险记录保留。

6. 可解释性与演示

默认输出固定包含标签、谣言概率、置信度、支持谣言证据、支持非谣言证据和综合判断。LLM 增强模块采用相似样本提示，将本地证据、近邻标签和输入推文发送给学校 API；高置信覆盖门槛为 0.85。运行 `python scripts/run_demo_server.py` 可打开本地前端页面，展示标签、概率、来源和中文判断依据。

7. 复现方式与分工

核心命令：`pip install -r requirements.txt`；`python -m src.train --with-explanations`；`python -m src.evaluate --show-examples 0`；`python scripts/run_final_detector_evaluation.py`；`python scripts/run_demo_server.py`。小组姓名、学号和贡献比例提交前填写。

8. 结论

本项目以可复现的 TF-IDF 集成模型作为正式主线，在 val.csv 上达到 0.8803 Accuracy，并提供基于局部特征贡献的解释。备选增强模型在不依赖 LLM 缓存的前提下达到 0.8928 Accuracy，展示了由错误分析驱动的召回改进。报告明确区分默认指标、增强实验和探索性失败结果。

参考文献

- Shu et al. Fake News Detection on Social Media: A Data Mining Perspective. ACM SIGKDD Explorations, 2017.
- Salton and Buckley. Term-weighting approaches in automatic text retrieval. Information Processing & Management, 1988.
- Pedregosa et al. Scikit-learn: Machine Learning in Python. JMLR, 2011.
- Lewis et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS, 2020.

附录：核心接口

```
from src.rumor_detector import RumourDetectClass
from src.final_detector import FinalRumourDetectClass

main_detector = RumourDetectClass(); label = main_detector.classify('input tweet text'); reason =
main_detector.explain('input tweet text')

final_detector = FinalRumourDetectClass(); result = final_detector.predict('input tweet text')
```